

— KARTA KATALOGOWA

Ocena modeli i systemów **AI**

Największym wyzwaniem nie jest dziś dostępność modeli AI, ale rzetelna ocena i wybór rozwiązania najlepiej dopasowanego do potrzeb organizacji.

W ostatnich latach pojawiły się setki modeli AI (m.in. GPT, Claude, LLaMA, Gemini, Mistral) od różnych dostawców technologii, takich jak Google, IBM, Microsoft czy polscy integratorzy. Rozwijają się one niezwykle szybko, a nowe wersje publikowane są co kilka miesięcy.

W tak dynamicznym środowisku wybór właściwego rozwiązania AI dla organizacji staje się coraz trudniejszy. Nie powinien on opierać się wyłącznie na popularności modelu ani na wynikach testów prezentowanych w materiałach marketingowych producentów. Kluczowe jest dopasowanie rozwiązania do konkretnych zastosowań, danych oraz sposobu działania organizacji.

Oznacza to konieczność oceny jakości odpowiedzi generowanych przez model AI pod kątem scenariuszy użycia w organizacji, a także uwzględnienia takich aspektów jak:

bezpieczeństwo danych

koszty wykorzystania modelu

stabilność działania i skalowalność

możliwość integracji z istniejącymi systemami

dostępność modeli w infrastrukturze lokalnej lub chmurowej

W przypadku scenariuszy związanych z tworzeniem treści szczególne znaczenie ma również jakość języka polskiego. Większość modeli AI trenowana była głównie na danych anglojęzycznych, co przekłada się na ograniczoną znajomość polskiej normy językowej oraz polskiego kontekstu kulturowego i prawnego. W efekcie w odpowiedziach generowanych po polsku mogą pojawiać się kalki językowe, nienaturalne konstrukcje lub uproszczenia wynikające z przenoszenia anglosaskich wzorców komunikacji.

Właściwie zaprojektowane testy pozwalają sprawdzić, czy model rzeczywiście nadaje się do pracy w środowisku polskojęzycznym, zwłaszcza w zastosowaniach wymagających precyzji językowej i znajomości lokalnego kontekstu. Podobne podejście stosuje się także do oceny innych aspektów działania rozwiązań AI.

Najlepszym sposobem takiej oceny jest uporządkowane porównanie wyników różnych modeli na tych samych zadaniach i danych. Takie podejście określa się mianem **benchmarku modeli AI**.

Czym jest benchmark modeli AI?

Benchmark to zestaw zadań oraz jasno zdefiniowanych kryteriów oceny, który pozwala w sposób kompleksowy porównywać jakość działania wybranych modeli AI we wskazanym obszarze zastosowań.

Benchmarki mają różny charakter:

ogólne

sprawdzają ogólne zdolności modeli, takie jak rozumienie tekstu, logika czy wiedza faktograficzna

domenowe

koncentrują się na konkretnych dziedzinach, np. medycynie, prawie czy finansach

zadaniowe

mierzą jakość modeli w konkretnych zadaniach, takich jak klasyfikacja dokumentów, wydobycie informacji czy streszczanie

Dlaczego warto stworzyć benchmark na własnych danych?

Choć publiczne benchmarki są bardzo przydatne w badaniach nad AI, w praktyce wdrożeń organizacyjnych często okazują się niewystarczające. Mierzą one ogólne zdolności modeli, ale rzadko odzwierciedlają rzeczywiste scenariusze zastosowań w organizacjach.

Benchmark przygotowany na realnych danych organizacji pozwala sprawdzić działanie modeli w kontekście rzeczywistych zadań, takich jak analiza dokumentów, zarządzanie wiedzą, obsługa zapytań użytkowników czy wsparcie procesów decyzyjnych.

Najważniejszą zaletą takiego podejścia jest możliwość podejmowania racjonalnych decyzji technologicznych. W wielu przypadkach okazuje się, że modele dostępne na rynku są już wystarczająco dobre do realizacji danego zadania i nie wymagają kosztownego trenowania ani dostrajania. Benchmark pozwala to sprawdzić w sposób obiektywny oraz wskazać obszary, w których douczenie modelu AI na nowych danych może znacząco poprawić jego skuteczność.

Jak wygląda proces wyboru modelu AI w organizacji?

W praktyce wybór modelu językowego powinien przebiegać w kilku krokach.

1

Identyfikacja scenariuszy zastosowań

Najpierw identyfikowane są realne scenariusze wykorzystania AI w organizacji, np. wsparcie obsługi klienta, wyszukiwanie informacji w bazach wiedzy czy automatyczne przygotowywanie raportów.

2

Analiza wyników w istniejących benchmarkach

W drugim kroku analizowane są wyniki modeli AI w dostępnych benchmarkach publicznych, które pozwalają wstępnie ocenić ich możliwości w danym typie zadań. W przypadku zastosowań polskojęzycznych szczególne znaczenie mają benchmarki oceniające poprawność językową oraz znajomość lokalnego kontekstu.

3

Testy modeli na danych organizacji

Na podstawie zidentyfikowanych scenariuszy przygotowywany jest benchmark oparty na danych i zadaniach odpowiadających rzeczywistym potrzebom organizacji. Różne modele AI są testowane na tym samym zestawie zadań, co pozwala porównać ich działanie pod kątem jakości odpowiedzi, kosztów wykorzystania oraz wydajności systemu.

4

Wybór modelu i architektury rozwiązania

Dopiero dzięki analizie wyników wewnętrznego benchmarku możliwe jest wskazanie najlepszego rozwiązania — zarówno w zakresie wyboru modelu AI, jak i architektury docelowego systemu, np. systemu RAG (Retrieval Augmented Generation).

Kiedy potrzebna jest adaptacja modelu?

Jeśli dostępne modele AI nie spełniają wymagań jakościowych, możliwe jest ich dalsze dostosowanie do potrzeb organizacji.

W zależności od problemu stosuje się różne strategie adaptacji modeli.

W niektórych przypadkach konieczne jest dostosowanie modelu do specyfiki danej domeny, np. jej terminologii i stylu komunikacji.

W innych sytuacjach wystarczy nauczyć model realizacji konkretnego zadania poprzez dostrojenie (fine-tuning).

Pierwsze podejście jest bardziej wymagające obliczeniowo i kosztowne, natomiast drugie pozwala szybciej osiągnąć oczekiwane rezultaty. **Quantica Lab** oferuje wsparcie w realizacji obu tych podejść.

Benchmark pozwala w sposób obiektywny ocenić, czy i jaka adaptacja jest rzeczywiście potrzebna, oraz wskazać najbardziej efektywną ścieżkę jej realizacji.

Jak możemy pomóc?

W naszej praktyce punktem wyjścia dla racjonalnego wyboru technologii jest rzetelne porównanie modeli AI w benchmarkach opartych na rzeczywistych danych i scenariuszach użycia. Nasze wsparcie nie ogranicza się jednak do oceny modeli — wspieramy organizacje na wszystkich etapach projektowania i wdrażania AI:

identyfikacji i definiowaniu kluczowych scenariuszy zastosowania AI

analizie wyników modeli AI w dostępnych benchmarkach, w tym benchmarkach oceniających ich dostosowanie do języka i kontekstu polskiego

opracowaniu benchmarków AI opartych na realnych danych i zadaniach organizacji

przygotowaniu i uporządkowaniu zbiorów danych organizacji

rekomendacji najlepszego modelu oraz architektury systemu

projektowaniu i wdrażaniu systemów opartych na modelach AI

adaptacji modeli poprzez kontynuację pretreningu lub dostrajanie (fine-tuning)

Dlaczego my?

Posiadamy szerokie doświadczenie w ewaluacji systemów AI, w tym w projektowaniu metod oceny, przygotowywaniu zbiorów testowych oraz analizie wyników modeli. Jesteśmy współautorami benchmarków służących do oceny jakości modeli językowych w różnych zadaniach i domenach.

Stosujemy systematyczne, naukowe podejście do projektowania i oceny systemów AI, wykorzystując najnowsze metody rozwijane w społeczności badawczej (state-of-the-art). Ocena modeli stanowi jednak dopiero pierwszy krok w procesie budowy rozwiązań AI. W bardziej wymagających zastosowaniach konieczna jest ich adaptacja do specyfiki danej domeny lub zadania. **Quantica Lab** wspiera organizacje zarówno w porównywaniu modeli poprzez benchmarki, jak i w ich dostrajaniu oraz wdrażaniu w docelowych systemach AI.

Dlaczego warto zacząć od benchmarku?

Największym wyzwaniem nie jest dziś dostępność modeli AI, ale rzetelna ocena i wybór rozwiązania najlepiej dopasowanego do potrzeb organizacji. Benchmark na własnych danych jest najprostszym sposobem sprawdzenia, czy rozpatrywane rozwiązanie spełnia kryteria wymagane do jego wdrożenia — zarówno pod względem jakości generowanych odpowiedzi, jak i szybkości działania czy kosztów infrastruktury. Pozwala przejść od opinii o modelach i marketingowych deklaracji producentów do mierzalnego porównania jakości i racjonalnej decyzji technologicznej.

KONTAKT

Porozmawiajmy o współpracy

Sprawdź, ile czasu i kosztów może zaoszczędzić Twoja organizacja. Napisz do nas — pokażemy nasze podejście w działaniu i omówimy scenariusz współpracy dopasowany do Twojej organizacji.

kontakt@quanticalab.aiwww.quanticalab.ai

Quanticalab Sp. z o.o.